



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de
Monterrey

Campus Puebla

TC3009C.601

Inteligencia artificial avanzada para la ciencia de datos
(Gpo 601)

Equipo 4:

Bruno Alejandro Domínguez Maldonado | A01738844

Jose Antonio Diaz Mendez | A01738341

Karol Anette Lozano González | A01734812

18 de septiembre de 2026

i. Correcciones del análisis exploratorio.

Cambio	Retroalimentación	Corrección realizada
Interpretación de valores repetidos	“Como sus variables son numéricas de tipo flotante el interés de ver los valores repetidos sería más bien como para realizar suposiciones sobre algún cargo o depósito de valor constante, por ejemplo, 5.0209 de la variable 68, pero su frecuencia es aún así baja, por lo que muy probablemente esta información no es útil.” Las repeticiones en variables flotantes tienen una frecuencia baja, por lo que aportan poca información útil.	Se dejó la revisión de repeticiones como análisis secundario, incorporando sus porcentajes y evitando atribuirles significados financieros sin evidencia.

ii. Correcciones de la preparación de los datos.

Cambio	Retroalimentación	Corrección realizada
Aislamiento de ID_code	“Esto no lo entendí: <pre>#guardar ID_code si todavía existe; en caso contrario, usar el índice if "ID_code" in train.columns: train_ids= train["ID_code"].copy() else: train_ids = pd.Series(train.index, name="ID_code") if "ID_code" in test.columns: test_ids =test["ID_code"].copy() else: test_ids= pd.Series(test.index, name="ID_code")"</pre>	Se aplicó <code>train.pop("ID_code")</code> para remover el identificador de la matriz de entrenamiento X, evitando que distorsione el escalado o genere fuga de datos (data leakage), reincorporándolo únicamente en la exportación final de los CSV.
Feature Engineering	“¿Por qué se puso en "duro" las 6 variables nuevas? <pre>print("Variables nuevas:", 6)</pre> ¿cómo se integran estas nuevas variables en el modelo ya que son variables de todo el	Finalmente decidimos que estas variables no cumplían un propósito o uso real para nuestros modelos, por lo que decidimos eliminar su creación.

	conjunto de datos?"	
Análisis de redundancia	Cuando ponen: "AUC máximo: 0.5672385728989442 AUC mínimo: 0.5001523291505247 AUC promedio: 0.5245280266478183 Variables con AUC strength > 0.55: 16 Variables con AUC strength > 0.60: 0 Como podemos ver, no contamos con variables redundantes." Cómo llegaron a la conclusión de que "no cuentan con variables redundantes"?	Se sustituyó el AUC por una matriz de correlación de Pearson (corr().abs()) en el triángulo superior, demostrando formalmente que la máxima correlación es 0.0098, confirmando 0 variables redundantes ($r > 0.85$).
Tratamiento del desbalance	En la sección 5. Tratamiento del desbalance de clases (si aplica) No tenía que haber corrido un modelo, sino sólo preparar los datos si era necesario.	Se removió la ejecución del modelo preliminar y únicamente se calculó la distribución de clases (89.95% vs 10.05%) y el factor de ponderación scale_pos_weight = 8.9512.
Almacenamiento de datasets	No entendí que hicieron en la sección 6 del notebook. ¿Por qué realizan todas esas operaciones?	Se construyó un script automatizado que exporta múltiples archivos CSV con selecciones de variables según ANOVA (200, 181, 100, 50 características) y su versión logarítmica lista para el modelado.
Transformación Logarítmica	Considerando las colas largas del análisis exploratorio, se recomienda probar con y sin base logarítmica en la transformación de los datos.	Se implementó la transformación np.log1p de manera controlada sobre las 200 variables continuas, calculando un desplazamiento automático para valores ≤ 0 y exportando la versión en base logarítmica por separado (train_200log.csv).

Link al repositorio de github:

<https://github.com/Ch1ps-Ch0l0c4Te/Entrega-de-la-soluci-n-del-Reto>